

Finansal Haberler Kullanılarak Derin Öğrenme ile Borsa Tahmini Stock Market Prediction with Deep Learning Using Financial News

Hakan Gündüz
Bilgisayar Mühendisliği Bölümü
{İstanbul Teknik, Düzce} Üniversitesi
{İstanbul, Düzce}, Türkiye
hakangunduz@itu.edu.tr

Yusuf Yaslan ve Zehra Çataltepe
Bilgisayar Mühendisliği Bölümü
İstanbul Teknik Üniversitesi
İstanbul, Türkiye
{yyaslan,cataltepe}@itu.edu.tr

Özetçe—Bu çalışmada Borsa İstanbul’da işlem gören 9 banka hissesinin hareket yönleri Uzun-Kısa Dönem Hafıza (UKDH) ağı ile tahmin edilmiştir. Tahmin işleminde finansal haberlerden elde edilen öznitelikler kullanılmıştır. Öznitelik oluşturma aşamasında kelime gömülmesi yöntemi Fasttext’ten ve finansal duygu sözlüğünden yararlanılmıştır. Saatlik hareket yönünü gösteren sınıf etiketleri ise hisselerin saatlik kapanış fiyatları kullanılarak bulunmuş ve oluşturulan öznitelik vektörleriyle hizalanmıştır. Tahmin işlemini gerçekleştirmek için iki farklı UKDH ağı eğitilmiş ve sınıflandırma performansı Makro-Ortalama (M.O.) F-Ölçütü metriğiyle değerlendirilmiştir. Yapılan deneylerle 9 hissenin hareket yönleri ortalama 0.540 M.O. F-Ölçütü oranıyla tahmin edilmiştir. Her iki UKDH ağıyla alınan sonuçlar Rastgele ve Naive kıyaslama yöntemlerinden yüksek olmasına rağmen, UKDH ağında Dikkat Mekanizmasının kullanılması sonucu olumlu olarak etkilememiştir.

Anahtar Kelimeler—*derin öğrenme, borsa yön tahmini, Borsa İstanbul(BİST), Uzun-Kısa Dönem Hafıza(UKDH), kelime gömülmesi, Fasttext.*

Özet—In this study, the hourly movement directions of 9 banking stocks in Borsa Istanbul were predicted using Long-Short Term Memory(LSTM) networks with features obtained from financial news. In the feature creation phase, the word embedding referred as Fasttext, and the financial sentiment dictionary were utilized. Class labels indicating the movement direction were computed based on hourly close prices of the stocks and they were aligned with obtained feature vectors. Two different LSTM networks were trained to perform the prediction, and the performance of the classification process was evaluated by the Macro Averaged (M.A) F-Measure. In the experiments, the movement directions of the 9 stocks were predicted with an average M.A F-measure rate of 0.540. Although the results of both LSTM networks were higher than the Random and Naive benchmark methods, the use of Attention Mechanism in the second LSTM network did not positively affect the results.

Keywords—*deep learning, stock market movement prediction, Borsa İstanbul(BİST), Long-Short Term Memory(LSTM), word embedding, Fasttext.*

I. GİRİŞ

Borsa piyasaları, ülke ekonomilerinin büyümelerini gösteren önemli bir finansal enstrümandır ve ticaret ve/veya sanayinin gelişmesinde hayati rol oynamaktadır. Borsa verilerinin analiz edilmesi ve borsa hareketlerinin öngörülmesi yatırımcıların, şirketlerin ve hükümetlerin ilgisini çekmektedir. Buna karşın, borsa piyasalarının öngörülebilir olup olmadığı konusunda tartışmalar bulunmakta ve öne sürülen "Rastgele Yürüyüş Teorisi"nde, hisse fiyatlarının rastgele belirlendiği ve dolayısıyla piyasadaki daha iyi performans elde etmenin imkansız olduğu belirtilmektedir [1]. Teorinin aksine hisseler ile ilgili nicel ve nitel veriler kullanılarak hisse fiyatları ve yönü ile ilgili tahminler yapılmaktadır. Nicel analiz, tahmin yaparken halka açık olan nicel verileri (Örneğin; hisse senedi fiyatı, bilanço değeri, kar-zarar tabloları vb.) kullanırken; nitel analiz, şirketin yönetimi, ürünleri ve stratejileri ile ilgili niteliksel verilerden faydalanır [2]. Nicel veriler, yapılandırılmış (tablo haline getirilmiş) verilerdir ve bu veriler teknik analiz yaklaşımı ile değerlendirilir. Nitel veriler ise web ortamı veya sosyal medya da dahil olmak üzere çeşitli veri kaynaklarından gelen metin açıklamalarından oluşmaktadır. Nitel veriler, nicel verilerin aksine yapılandırılmamış olduğundan tahmin işleminde kullanılması için ön işleme tabi tutulur [3].

Borsa piyasalarının analizinde nicel ve nitel analiz yöntemlerinin yanında son yıllarda yapay öğrenme yöntemleri de sıklıkla kullanılmaya başlamıştır. Lojistik Regresyon (LR), Rastgele Ormanlar (RO), Destek Vektör Makineleri (DVM) ve Yapay Sinir Ağları (YSA) gibi yapay öğrenme modelleriyle hisse senedi fiyatları veya fiyat değişimleri başarı ile tahmin edilmiştir. Yapay öğrenmeyi kullanan bu çalışmalarda, giriş verisi olarak ham fiyat verileri, fiyat verilerinden hesaplanan teknik göstergeler ve makroekonomik veriler kullanılmıştır [4]. Son 10 yılda yatırımcıların bilgi kaynaklarına erişiminin artması ve hisse senetleri ile ilgili haberlere gerçek zamanlı olarak erişimin kolaylaşması borsa tahmininde metinsel verilerin kullanımının önünü açmıştır. [5]–[8] tarafından yapılan çalışmalarda siyasi ve ekonomi haberlerin ve hisse senetlerine ilişkin olayların, hisse senetlerinin oynaklığında önemli rol oynadığı kanıtlanmıştır. Bu çalışmalarda web metinlerinin borsa tahmini üzerindeki etkisini analiz etmek için Doğal Dil İşleme

(İng. Natural Language Processing) teknikleri kullanılmıştır.

Yapılan çalışmada Borsa İstanbul'da (BIST) yer alan 9 banka hissenin saatlik fiyat değişimleri haber metinleri kullanılarak tahmin edilmiştir. Tahminde Özyineli Sinir Ağının (İng. Recurrent Neural Networks-RNN) (ÖSA) bir türü olan Uzun-Kısa Dönem Hafıza (İng. Long-Short Term Memory-LSTM) (UKDH) ağı kullanılmıştır. Sınıflandırıcılara girdi verisi olarak haber metinlerinden elde edilen öznitelikler verilmiştir. Haber metninin öznitelik vektörlerine dönüştürülmesi için Facebook tarafından geliştirilen kelime gömülmesi (İng. Word Embedding) yöntemi Fasttext [9] ve finansal duygu sözlüğü (Loughran and McDonald Financial Sentiment Dictionary) [10] kullanılmıştır. Böylece her bir haber metni 103 boyutluk yoğun vektörlerle ifade edilmiştir. Elde edilen haber vektörleri ile UKDH sınıflandırıcıları eğitilmiş ve sınıflandırma performansları ölçülmüştür. Kurulan UKDH mimarilerinin performans değerlendirilmesi, sınıf dağılımının dengesiz olması nedeniyle, doğruluk yerine Makro-Ortalama F-Ölçütü ile yapılmıştır.

Çalışmamız diğer borsa tahmini çalışmalarına göre iki yeniliğe sahiptir. Birinci yenilik haber metnlerinin işleme yöntemidir. Literatürdeki çalışmaların birçoğunda haber metinleri kelimeler çantası (İng. Bag of words) yöntemiyle öznitelik vektörlerine dönüştürülmüştür [4]. Çalışmamızda ise bu aşama Facebook tarafından geliştirilen kelime gömülmesi yöntemiyle yapılmış ve haber metinleri yoğun vektörler ile ifade edilmiştir. İkinci yenilik ise derin öğrenme yöntemi olan Uzun-Kısa Dönem Hafıza (UKDH) ağına kullanılmasıdır. Borsa İstanbul'un tahmininde daha önce Evrişimsel Sinir Ağları'nı (İng. Convolutional Neural Networks) kullanan çalışmalar [11], [12] olmasına rağmen, çalışmamız bildiğimiz kadarıyla UKDH ağını kullanan ilk çalışmadır. Çalışmamızın geri kalan kısmı aşağıdaki şekilde düzenlenmiştir. Bölüm 2, borsa tahminine ilişkin önceki çalışmaları içermektedir. Kullanılan Yöntemler Bölüm 3'de ayrıntılı olarak açıklanmıştır. Bölüm 4'te ise alınan deneysel sonuçlara ve değerlendirmelere yer verilmiştir.

II. İLGİLİ ÇALIŞMALAR

Bu bölümde Borsa İstanbul ile ilgili yapılan tahmin çalışmalarına ve derin öğrenme kullanan borsa tahmini çalışmalarına yer verilmiştir.

A. Borsa İstanbul Çalışmaları

Bildirici ve Ersin [13], BIST 100 endeksinin günlük getiri değerini YSA ve Otoregresyon modelleri ile tahmin etmiştir. [14] yaptığı çalışmada BIST 100 endeksinin hareket yönünü tahmin etmek için YSA ve DVM kullanmıştır. Her iki modele giriş verisi olarak fiyat verisinden hesaplanan teknik göstergeler verilmiştir.

[12] çalışmasında günlük yayınlanan finansal haber metinleri ile BIST 100 endeksinin yönünü tahmin etmiştir. Çalışmada finansal haber metinleri doğal dil işleme teknikleri ile öznitelik vektörlerine dönüştürülmüş ve veri kümesindeki sınıf dağılımları dikkate alınarak yenilikçi bir öznitelik seçim yöntemi önerilmiştir. Pehlivanlı ve diğ. [15] BIST hisselerinin ertesi gün fiyat trendini öngörmek için teknik ve makro-ekonomik göstergeleri kullanmış ve veri kümesinden ilgisiz öznitelikleri elemek için filtre temelli öznitelik seçim yöntemlerini birleştirmiştir. Seçilen özniteliklerle DVM sınıflandırıcısı eğitilmiş ve önerilen öznitelik seçme yöntemi sınıflandırma performansını arttırmıştır.

B. Derin Öğrenme Kullanan Borsa Tahmini Çalışmaları

Son yıllarda, derin öğrenme modelleri büyük ilgi görmüş ve güneş enerjisi tahmini, enerji yükü tahmini ve hava tahmini gibi zaman serisi tahminlerinde kullanılmıştır. Borsa çalışmalarında basit bir YSA yerine Evrişimsel Sinir Ağları, Otokodlayıcılar (İng. Autoencoders) ve Uzun-Kısa Dönem Hafıza ağları gibi derin öğrenme modelleri kullanılmıştır [11].

[16] yaptığı çalışmada ABD Nasdaq Borsası'nda işlem gören hisse fiyatlarının yönünü tahmin etmede derin öğrenme yapısı olan Yığılmış Otokodlayıcıları kullanmıştır. Derin öğrenme modeline giriş verisi olarak fiyat verisinden hesaplanan teknik göstergeler verilmiştir. Modelin başarımlı performansı kesinlik ve F-ölçütü ile değerlendirilmiş ve önerilen model DVM yöntemiyle beraber en iyi performansı vermiştir. Chen ve diğ. [17] UKDH ağını kullanarak Çin hisse senedi getirilerini tahmin etmiştir. Geçmiş Çin Borsası verileriyle 10 özniteliğe sahip 30 günlük uzunlukta iki boyutlu veri noktaları oluşturulmuş ve sınıf etiketi olarak veri noktalarına 3 günlük kazanç oranı atanmıştır. Rastgele tahmin yöntemi ile karşılaştırıldığında, UKDH modeli hisse senedi getiri tahmininde daha başarılı olmuştur. Gündüz ve diğ. [11], Borsa İstanbul 100 endeksinde yer alan hisselerin saatlik değişim yönünü Evrişimsel Sinir Ağı (ESA) ile tahmin etmiştir. Hisse fiyatlarından hesaplanan teknik göstergelerin öznitelik olarak kullanıldığı bu çalışmada, hem geçmiş saat dilimine ait öznitelikler hem de öznitelik arasındaki korelasyonlar dikkate alınmıştır. Çalışmada ESA ile elde edilen sınıflandırma performansı Ki-Kare öznitelik seçimi ve Lojistik Regresyon sınıflandırıcısı ile elde edilene göre daha yüksek olmuştur.

III. KULLANILAN YÖNTEMLER

Bu bölümde öznitelik oluşturma aşamaları, Uzun-Kısa Dönem Hafıza (UKDH) ağı sınıflandırıcısı ve performans değerlendirme ölçütü detaylandırılmıştır.

A. Öznitelik Oluşturma

Çalışmada kullanılan veri kümesi, BIST 100 Endeksinde listelenen 9 bankanın saatlik hisse senedi fiyatlarını içermektedir. Veri kümesinde her hisse senedi için Ocak 2011 ile Aralık 2015 tarihleri arasında (6705 işlem saati) saatlik kapanış fiyatı bulunmaktadır. Veri kümesi, eğitim kümesi ve test kümesi olmak üzere iki bölüme ayrılmıştır. Eğitim kümesi (Ocak 2011 - Aralık 2014 arası) ve test kümesi (Ocak 2015 - Aralık 2015 arası).

Fiyat verilerinin alındığı zaman aralığında yayınlanan yaklaşık 238000 haber bulunmaktadır. Bu haber metinleri ilk aşamada yayınlanma tarihine ve saatine göre gruplanmıştır. Gruplama işleminden sonra haber metinleri öznitelik vektörlerine dönüştürülmüştür. Dönüştürme işlemi aşağıdaki adımları içermektedir:

- 1) Bulunan Loughran and McDonald [10] finansal duygu sözlüğündeki negatif ve pozitif duyguya ait sözcükler Google Translate aracılığıyla Türkçe'ye çevrilmiştir.(2373 negatif ve 383 pozitif sözcük)
- 2) Facebook tarafından geliştirilen kelime gömülmesi yöntemi Fasttext [9] ile elde edilen kelime vektörleri bulunmuştur. Bu kelime vektörleri Wikipedia'da yer

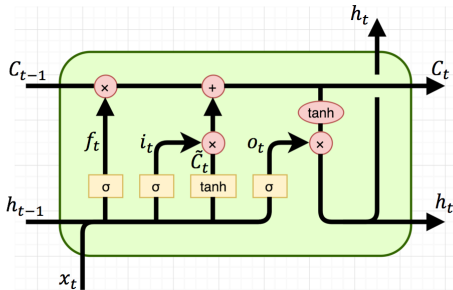
alan Türkçe makaleler üzerinde eğitilmiş ve sonucunda her bir tekil kelime için 300 boyutlu yoğun vektör oluşturulmuştur.

- 3) Elde edilen Fasttext vektörlerinden negatif ve pozitif sözcüklere ait olanlar bulunmuş ve hiyerarşik kümelemeye tabi tutulmuştur. Kümeleme ile anlamsal olarak yakın kelimelerin bulunması hedeflenmiştir. Hiyerarşik kümelemede benzerlik ölçütü olarak Kosinüs benzerliği kullanılmış ve küme birleştirme yöntemi olarak ortalama bağlantı seçilmiştir. Kümeleme sonucunda **103** adet küme oluşmuş ve bu kümelerin ortancaları (İng. Medoids) alınmıştır.
- 4) Her bir haber dokümanı için Fasttext kelime vektörlerinden öznitelik vektörleri oluşturulmuştur. Bunun için haber dokümanlarındaki kelimelerin Fasttext vektörü karşılıkları bulunmuş ve bu vektörlerin ortalaması alınmıştır. Böylece her haber **300** boyutluk vektörle ifade edilmiştir.
- 5) Haber vektörlerini duygu sözcüğü vektörleri cinsinden ifade etmek için haber vektörleri ile duygu sözcükleri kümelerinin ortancaları arasındaki Kosinüs benzerliğine bakılmıştır. Böylece her haber dokümanları **103** boyutlu vektörlerle ifade edilmiştir.

Haber dokümanlarına ait vektörlerin elde edilmesinden sonra, her saat diliminde yayınlanan haberler de kümelemeye tabi tutulmuştur. Kümeleme işleminde K-ortalama yöntemi kullanılmış ve küme sayısı (k) olarak 5 seçilmiştir. Her saat dilimindeki 5 kümenin merkez vektörlerinin ortalaması alınarak, o saat dilimi 103 boyutlu tek bir vektör ile temsil edilmiştir. Her hisse için öznitelik vektörleri oluşturulduktan sonra hisselerin fiyat değişimini gösteren sınıf etiketleri belirlenmiştir. Hisse senedinin fiyatı bir önceki saat dilimine göre arttı ise sınıf etiketi olarak "+1", azaldı ise "-1" atanmıştır.

B. Uzun-Kısa Dönem Hafıza (UKDH) Ağları

Uzun-Kısa Dönem Hafıza Ağları (UKDH), uzun vadeli bağımlılıkları öğrenebilen özel bir Özyineli Sinir Ağları (ÖSA) (İng. Recurrent Neural Networks- RNN) türüdür. UKDH, Hochreiter ve Schmidhuber [18] tarafından tanıtılmış ve çeşitli problemlerde iyi performans göstermiştir. UKDH'de tek bir sinir ağı katmanı yerine, çok özel bir şekilde etkileşime giren dört katman vardır. UKDH ağına ait şema Şekil 1'de gösterilmiştir. Şekilde, her siyah yol, bir düğümün çıkışından diğerlerinin girişine kadar tüm bir vektörü taşır. Sarı kutular öğrenilen sinir ağı katmanlarını, pembe daireler ise vektör eklenmesi gibi noktasal işlemleri temsil eder.



Şekil 1: UKDH Ağı iç yapısı.

UKDH'nin anahtarı hücre durumudur (İng. Cell state). UKDH, kapılar denilen yapılarla hücre durumuna (C_{t-1}) bilgi ekleme veya çıkarma yeteneğine sahiptir. Kapılar, isteğe bağlı olarak bilgi vermenin bir yoludur ve *sigmoid* sinir ağı katmanı ve noktalı çarpma işleminden oluşur. Sigmoid katman, sıfırdan bire kadar sayıları çıktı olarak verir ve her bileşenin ne kadarına izin verileceğini açıklar. UKDH, hücre durumunu korumak ve kontrol etmek için bu kapılardan üçüne sahiptir. UKDH'nin ilk adımı hangi bilginin hücre durumundan atılacağına karar vermektir. Bu karar, "unut kapısı katmanı (f_t)" olarak adlandırılan sigmoid bir katman ile alınır. Bir sonraki adım, hücre durumuna hangi yeni bilginin depolanacağına karar vermektir. Bu iki bölümden oluşur. İlk olarak, "giriş kapısı katmanı (i_t)" olarak adlandırılan bir sigmoid katman hangi değerlerin güncelleneceğine karar verir. Daha sonra bir *tanh* katmanı, duruma eklenebilecek yeni bir aday değer vektörü olan (C_m)'yi yaratır. Bir sonraki adımda, durum vektörünü güncellemek için (C_m) ve (C_{t-1}) birleştirilir. Böylece eski hücre durumu olan (C_{t-1}) yeni hücre durumu (C_t)'ye güncellenir. Son olarak, hücrenin hangi bölümlerinin çıktı olarak vereceğini kararlaştıran bir "çıkış katmanı (o_t)" çalıştırılır. Daha sonra, hücre durumu *tanh* aktivasyon fonksiyonundan geçirilir ve çıkış kapısının çıktısıyla çarpılır. Böylece kararlaştırılan parçalar çıktı (h_t) olarak verilir.

UKDH'ler, dizideki her zaman adımı için bir çıktı vektörü üretir ve mevcut zaman adımının çıktı vektörünü dizinin önceki zaman adımlarına bağlı hale getirir. UKDH'leri kullanmanın en yaygın yolu, dizideki son zaman adımının çıkış vektörünü (h_t) (öznitelik temsili) tüm dizinin temsili olarak almaktır. Sadece son zaman adımının vektörü alınarak, değişken uzunlukta bir dizi sabit uzunluklu bir vektöre çevrilebilir. Bu yaklaşım, bir dizinin bir vektöre indirgenmesinden dolayı bilgi kaybına yol açabilecektir. Bu durumun önüne geçebilmek için son zaman adımının çıktı vektörünü kullanmak yerine, tüm adımların çıktı vektörleri kullanılır. Böylece t. zaman adımındaki tahmin işlemi, girdi dizisinin tüm çıkış vektörünün toplanmasına bağlı olur ve UKDH hangi zaman adımlarının önemli olduğunu seçerek sabit uzunluk vektörünü oluşturmak için bu adımları bilgi olarak kullanabilir. Bu yaklaşıma **Dikkat Mekanizması** (İng. **Attention Mechanism**) adı verilmektedir. Bu mekanizma ile UKDH katmanının çıkışına bir veya daha fazla yoğun katman eklenerek her bir zaman adımına bir ağırlık atanmaktadır. Atanan ağırlıkların belirlenmesi ağı eğitimi sırasında olmaktadır.

C. Performans Değerlendirme

Sınıflandırıcının her sınıfı ayırt etme başarısının ölçülebilmesi için doğruluk oranının yerine kesinlik (İng. Precision), duyarlılık (İng. Recall) ve ikisinin bileşimi olan F-Ölçütü ölçütlerinin kullanılması gerekir. F-Ölçütü, kesinlik ve duyarlılık değerlerinin ağırlıklı harmonik ortalamasının alınması sonucu hesaplanır. Yüksek F-Ölçütü değeri iyi bir sınıflandırma performansı anlamına gelmektedir.

F-Ölçütü sınıflandırıcı performansını sınıf bazında değerlendirmekte ve değerlendirmede pozitif sınıfı baz almaktadır (İkili sınıflandırma probleminde). Sınıflandırıcının genel performansını değerlendirmek için F-Ölçütü'nü temel olarak oluşturulan Makro-Ortalama (M.O.) yöntemi bulunmaktadır. Makro-Ortalama performansı hesaplanırken ilk önce her sınıf

için performans ölçümü yapılmakta daha sonra sınıf performansı ölçümlerinin ortalaması alınmaktadır. Makro-Ortalama her sınıfa eşit ağırlık vermektedir [11].

IV. DENEYSEL SONUÇLAR VE DEĞERLENDİRME

Oluşturulan UKDH ağlarının performanslarını karşılaştırmak için, iki zaman serisi kıyaslama yöntemi kullanılmıştır. Bunlar Rastgele ve Naive yaklaşımlardır. Birinci kıyaslama yöntemi olan Rastgele yaklaşımda, fiyat yönleri (sınıf etiketleri) sınıf dağılımlarına dayanarak rastgele olarak atanır. Bu yaklaşımda, her sınıfın önsel olasılığı (İng. Prior probability), eğitim verilerindeki sınıf dağılımları kullanılarak bulunur. Ardından, birikimli olasılıklar (İng. Cumulative probabilities) bulunmuş olasılık değerlerine göre hesaplanır. Son olarak 0 ile 1 arasında rastgele değerler üretilir ve sınıf etiketleri, bu değerlerin birikimli olasılıkların içinde bulunduğu aralığa göre belirlenir. İkinci kıyaslama yöntemi olan Naive yaklaşımda, t .gündeki sınıf etiketine $t - 1$. günün sınıf etiketi atanır. Bu yaklaşımların kullanıldığı sınıflandırma sonuçları, her hisse için Tablo I’de verilmiştir. Sonuçlar, Rastgele yaklaşımın ortalama M.O. F-Ölçütünün, Naive yaklaşımdan daha iyi olduğunu ve sınıflandırma performansının % 50.1 civarında olduğunu göstermektedir.

Kıyaslama yöntemleriyle sonuçlar alındıktan sonra UKDH ağı ile haber öznitelikleri kullanılarak deneyler yapılmıştır. İlk kurulan UKDH ağında sadece son zaman adımından elde edilen temsiller kullanılırken, ikinci ağıda tüm zaman adımlarından elde edilen temsiller "Dikkat Mekanizması" ile birlikte kullanılmıştır. Sınıflandırıcılar her hisse için, Tablo II’de gösterilen hiper parametrelerle KERAS [19] paketi kullanılarak eğitilmiştir. Tanımlanan bu hiper parametreler eğitim kümesi üzerinde 5 kat çapraz doğrulama ile bulunmuştur. Hisse bazında alınan sınıflandırma sonuçları Tablo I’de gösterilmiştir. UKDH’nin son zaman adımından elde edilen temsillerle, 0.540 ortalama M.O. F-Ölçütü oranına ulaşılırken, dikkat mekanizması kullanıldığında 0.534 ortalama M.O. F-Ölçütü oranı elde edilmiştir. Her iki UKDH ağı ile alınan sonuç Naive ve Rastgele yöntemlerinden daha yüksek olmasına rağmen dikkat mekanizmasının kullanılması sınıflandırma performansını olumlu olarak etkilememiştir. Hisse bazında ise en yüksek M.O. F-Ölçütü oranına YKBNK (0.557) hissesinde ulaşılmıştır.

Tablo I: SINIFLANDIRMA SONUÇLARI

| Hisse | Rastgele | Naive | Haber Dikkat Mek. | Haber |
|-----------------|--------------|--------------|-------------------|--------------|
| AKBNK | 0.503 | 0.509 | 0.549 | 0.554 |
| ALBRK | 0.51 | 0.4 | 0.518 | 0.513 |
| GARAN | 0.496 | 0.499 | 0.544 | 0.535 |
| HALKB | 0.5 | 0.485 | 0.556 | 0.55 |
| ISCTR | 0.493 | 0.5 | 0.527 | 0.549 |
| SKBNK | 0.505 | 0.426 | 0.549 | 0.555 |
| TSKB | 0.509 | 0.444 | 0.538 | 0.528 |
| VAKBN | 0.493 | 0.493 | 0.49 | 0.526 |
| YKBNK | 0.503 | 0.483 | 0.536 | 0.557 |
| Ortalama | 0.501 | 0.471 | 0.534 | 0.540 |

TEŞEKKÜR

Yazarlar, çalışmada kullanılan verileri sağlayan Matriks Bilgi Dağıtım Hiz. A.Ş’ye teşekkürü borç bilir.

Tablo II: UKDH AĞI PARAMETRELERİ

| Parametre | (Değer) |
|----------------------------|---------|
| UKDH Hafıza Hücresi Sayısı | {30} |
| Yineleme Bırakma Oranı | {0.8} |
| Optimizasyon | {Adam} |
| Aktivasyon Fonksiyonu | {RELU} |
| İterasyon Sayısı | {100} |
| Yığın Boyutu | {32} |
| L2 Düzenleyici Katsayısı | {0.05} |

KAYNAKLAR

- [1] B. G. Malkiel, "The efficient market hypothesis and its critics," *Journal of economic perspectives*, vol. 17, no. 1, pp. 59–82, 2003.
- [2] P. Holmes and K. Paudyal, "Editorial," *Review of Behavioural Finance*, vol. 4, no. 1, 2012.
- [3] C. Kearney and S. Liu, "Textual sentiment in finance: A survey of methods and models," *International Review of Financial Analysis*, vol. 33, pp. 171–185, 2014.
- [4] R. C. Cavalcante, R. C. Brasileiro, V. L. Souza, J. P. Nobrega, and A. L. Oliveira, "Computational intelligence and financial markets: A survey and future directions," *Expert Systems with Applications*, vol. 55, pp. 194–211, 2016.
- [5] R. Schumaker and H. Chen, "Textual analysis of stock market prediction using financial news articles," *AMCIS 2006 Proceedings*, p. 185, 2006.
- [6] P. C. Tetlock, "Giving content to investor sentiment: The role of media in the stock market," *The Journal of finance*, vol. 62, no. 3, pp. 1139–1168, 2007.
- [7] M. Baker and J. Wurgler, "Investor sentiment in the stock market," *Journal of economic perspectives*, vol. 21, no. 2, pp. 129–152, 2007.
- [8] X. Li, H. Xie, L. Chen, J. Wang, and X. Deng, "News impact on stock price return via sentiment analysis," *Knowledge-Based Systems*, vol. 69, pp. 14–23, 2014.
- [9] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov, "Enriching word vectors with subword information," *arXiv preprint arXiv:1607.04606*, 2016.
- [10] T. Loughran and B. McDonald, "Ipo first-day returns, offer price revisions, volatility, and form s-1 language," *Journal of Financial Economics*, vol. 109, no. 2, pp. 307–326, 2013.
- [11] H. Gunduz, Y. Yaslan, and Z. Cataltepe, "Intraday prediction of borsa istanbul using convolutional neural networks and feature correlations," *Knowledge-Based Systems*, vol. 137, pp. 138–148, 2017.
- [12] H. Gunduz, Z. Cataltepe, and Y. Yaslan, "Stock market direction prediction using deep neural networks," in *Signal Processing and Communications Applications Conference (SIU), 2017 25th. IEEE*, 2017, pp. 1–4.
- [13] M. Bildirici and Ö. Ö. Ersin, "Improving forecasts of garch family models with the artificial neural networks: An application to the daily returns in istanbul stock exchange," *Expert Systems with Applications*, vol. 36, no. 4, pp. 7355–7362, 2009.
- [14] Y. Kara, M. A. Boyacioglu, and Ö. K. Baykan, "Predicting direction of stock price index movement using artificial neural networks and support vector machines: The sample of the istanbul stock exchange," *Expert systems with Applications*, vol. 38, no. 5, pp. 5311–5319, 2011.
- [15] A. Ç. Pehlivanlı, B. Aşıkil, and G. Gülay, "Indicator selection with committee decision of filter methods for stock market price trend in ise," *Applied Soft Computing*, vol. 49, pp. 792–800, 2016.
- [16] A. C. Türkmen and A. T. Cemgil, "An application of deep learning for trade signal prediction in financial markets," in *Signal Processing and Communications Applications Conference (SIU), 2015 23th. IEEE*, 2015, pp. 2521–2524.
- [17] K. Chen, Y. Zhou, and F. Dai, "A lstm-based method for stock returns prediction: A case study of china stock market," in *Big Data (Big Data), 2015 IEEE International Conference on. IEEE*, 2015, pp. 2823–2824.
- [18] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [19] F. Chollet *et al.*, "Keras."