

# Derin Sinir Ağları ile Borsa Yönü Tahmini Stock Market Direction Prediction Using Deep Neural Networks

Hakan GUNDUZ, Zehra CATALTEPE, Yusuf YASLAN

Bilgisayar Mühendisliği Bölümü

İstanbul Teknik Üniversitesi

İstanbul, Türkiye

{hakangunduz, cataltepe, yyaslan}@itu.edu.tr

**Özetçe** —Bu çalışmada Borsa İstanbul’da en çok işlem gören hisselerden GARAN, THYAO ve ISCTR hisselerinin günlük değişim yönleri derin sinir ağları ile tahmin edilmiştir. Tahmin işleminde öznitelik olarak hisse ve dolar-altın fiyatlarından elde edilen teknik göstergeler kullanılmıştır. Günlük değişim yönünü gösteren sınıf etiketleri ise hisselerin günlük kapanış fiyatları kullanılarak bulunmuş ve oluşturulan öznitelik vektörleriyle hizalanmıştır. Tahmin işlemini gerçekleştirmek için Derin Sinir Ağı çeşidi olan Evrişimsel Sinir Ağı eğitilmiş ve sınıflandırma işleminin performansı doğruluk oranı ve F-Ölçütü metrikleriyle değerlendirilmiştir. Yapılan deneylerle GARAN, THYAO ve ISCTR hisselerinin değişim yönleri sırasıyla 0.61, 0.578 ve 0.574 doğruluk oranlarıyla tahmin edilmiştir. Sadece fiyat özniteliklerinin kullanılmasıyla kıyaslandığında, dolar-altın özniteliklerinin kullanılması sınıflandırma performansını arttırmıştır.

**Anahtar Kelimeler**—borsa tahmini, borsa yön tahmini, Borsa İstanbul(BİST), derin sinir ağları, evrişimsel sinir ağları.

**Abstract**—In this study, the daily movement directions of three frequently traded stocks (GARAN, THYAO and ISCTR) in Borsa Istanbul were predicted using deep neural networks. Technical indicators obtained from individual stock prices and dollar-gold prices were used as features in the prediction. Class labels indicating the movement direction were found using daily close prices of the stocks and they were aligned with the feature vectors. In order to perform the prediction process, the type of deep neural network, Convolutional Neural Network, was trained and the performance of the classification was evaluated by the accuracy and F-measure metrics. In the experiments performed, using both price and dollar-gold features, the movement directions in GARAN, THYAO and ISCTR stocks were predicted with the accuracy rates of 0.61, 0.578 and 0.574 respectively. Compared to using the price based features only, the use of dollar-gold features improved the classification performance.

**Keywords**—stock market prediction, stock market movement prediction, Borsa Istanbul(BIST), deep neural networks, convolutional neural networks.

## I. GİRİŞ

Finansal piyasalar özellikle gelişmekte olan ülkelerin piyasaları, küreseler ve yerel ekonomik gelişmeler, politik olaylar, yatırımcıların beklentileri gibi birçok etmeden etkilenmektedir. Bu etmenler arasındaki karmaşık ve doğrusal olmayan ilişkiler, finansal enstrümanların fiyatının tahminini çekici bir

konu haline getirmiştir. Örneğin, finansal piyasaların önemli enstrümanlarından olan borsa tahmininde hisselerin geçmiş fiyatlarından hesaplanan teknik göstergeler ve küresel ve yerel ekonomik veriler kullanılarak hisse fiyatlarının yönü/fiyatı tahmin edilmektedir. Son yıllarda yapılan borsa tahmini çalışmalarında ise borsa verisindeki karmaşık ve doğrusal olmayan ilişkiler makine öğrenmesi yöntemleri ile modellenmiştir. Giriş verisi olarak finansal haber metinlerinin, hisse fiyatlarının ve bu fiyatlardan hesaplanan teknik göstergelerin kullanıldığı bu çalışmalarda Lojistik Regresyon (LR) [1], Yapay Sinir Ağları (YSA) [2], [3], Destek Vektör Makineleri (DVM) [4], ve Naive Bayes (NB) [5] yöntemleri ile başarılı sonuçlar alınmıştır. Bu yöntemlerden YSA ve DVM verideki doğrusal olmayan ilişkileri modellemedeki başarısı ile ön plana çıkmıştır [6]. Borsa tahmininde YSA sıklıkla kullanılmasına rağmen YSA eğitiminde çeşitli problemler ortaya çıkabilmektedir. Bunlardan en önemlisi, sinir ağlarında global optimum parametrelerin bulunmasının garanti edilememesidir. Diğerleri ise öznitelik boyutu arttığında uzayın hacmi hızla genişlemekte bu da seyrek veriye neden olmaktadır. Veri boyutunun azaltılması için öznitelik seçim yöntemleri kullanılırken [7], bu yöntemler alan uzmanlığına dayandığından zaman alıcı ve işgücü gerektiren bir süreçtir. Bu durumla baş edebilmek için son yapılan zaman serisi tahmini çalışmalarında giriş verisinden öznitelik temsillerini direkt olarak çıkarabilen derin öğrenme yapıları kullanılmıştır. Bu çalışmada hisse fiyatları kullanılarak hisselerin günlük kapanış fiyatlarının yönü Derin Sinir Ağlarının bir çeşidi olan Evrişimsel Sinir Ağları (ESA) sınıflandırıcısı kullanılarak tahmin edilmiştir. Tahmin işleminde hisselerin günlük kapanış, açılış, en yüksek ve en düşük fiyatlarının yanı sıra emtia (altın) ve kur (dolar) fiyatlarından da yararlanılmış ve bu fiyat verilerden hesaplanan teknik göstergeler ESA’ya giriş verisi olarak verilmiştir. ESA’nın sınıflandırma performansı doğruluk ve F-Ölçütü metrikleriyle değerlendirilmiştir.

Çalışmanın geri kalan kısmı şu şekildedir: Bir sonraki bölümde literatürde yer alan ilgili çalışmalar özetlenecektir. 3.Bölüm’de çalışmada kullanılan veri kümesi ve uygulanan yöntemler, 4. Bölüm’de ise deneysel sonuçlar açıklanacaktır. Son bölümde, elde edilen deney sonuçları irdelenecektir.

## II. İLGİLİ ÇALIŞMALAR

Yapılan borsa tahmini çalışmalarının büyük bölümünde öznitelik olarak hisse fiyatları ve teknik göstergeler kullanılır

miştir. Son yıllarda yapılan çalışmalarda ise finansal haber metinlerinin kullanıldığı çalışmalarda bulunmaktadır.

Bildirici ve Ersin [8], Yapay Sinir Ağları ile birlikte Otoresif modelleri kullanarak günlük BİST 100 endeksinin dönüş değerini tahmin etmiştir. Boyacıoğlu ve Avcı [9] ise BIST 100 endeksinin dönüşünü ANFIS (Adaptive Neuro Fuzzy Inference System) sınıflandırıcısı ile tahmin etmiştir. [10] yaptığı çalışmada BIST 100 endeksinin yönünü tahmin etmek için teknik göstergelerden yararlanmış ve tahminde Yapay Sinir Ağları ve Destek Vektör Makineleri kullanmıştır. Tahmin işleminde iki sınıflandırıcı da iyi performans göstermiştir.

Metinsel ve fiyat verilerinin birlikte kullanıldığı çalışmada, öznitelik seçimi ile tahmin performansının arttığı görülmüştür [11]. Çalışmada Adım Adım Regresyon analizi tabanlı öznitelik seçimi yöntemi kullanılarak Destek Vektör Regresyonu ve Trend Segmentasyonu metotları ile momentum tahmini yapılmış ve alım ve satım sinyallerinin üretilmesi sağlanmıştır.

[12] tarafından yapılan çalışmada ise tüm haber metni yerine haber başlıkları kullanılarak Forex Piyasası tahmini yapılmıştır. Anlamsal ilişkilerden yararlanmak için WordNet ontolojisinden yararlanılmıştır. Çalışmada öznitelik seçiminde hiyerarşik yöntem kullanılmıştır.

[13] yaptıkları çalışmada Derin Sinir Ağlarını hisse senetlerinin hareket yönünü tahmin etmede kullanmıştır. Oluşturdukları modelde hem fiyat verileri hem de haber verileri kullanılmıştır. 1024 saklı katmana sahip derin sinir ağları ile sınıflandırma yapıldığında haber metinlerinden elde edilen özniteliklerin fiyat özniteliklerine eklenmesiyle tahmin performansının arttığı görülmüştür.

Finans alanında yapılan diğer bir çalışmada ise derin sinir ağları çeşidi olan otokodlayıcı kullanılmıştır. Çalışmada eğitim ve test kümeleri verisi S&P 500, Nasdaq ve AMEX borsalarındaki hisselerden elde edilmiş ve momentumun hisse fiyatları üzerindeki etkisi incelenmiş ve %46,2'lik test hatası bulunmuştur [14].

Hisse alım satımı karar sistemi tasarlamak için yapılan çalışmada Derin İnanma Ağları kullanılmıştır. Eğitim ve test kümeleri olarak S&P 500'de yer alan şirketlerin hisseleri kullanılmıştır. Sistem ile al ve bekle stratejisinden daha iyi bir sonuç elde edilmiştir [15].

[16] yaptığı çalışmada ABD Nasdaq Borsası'nda işlem gören hisse fiyatlarının yönünü tahmin etmede Derin Öğrenme Yapısı olan Yığılmış Otokodlayıcıları kullanmıştır. Derin öğrenme modeline giriş verisi olarak fiyat verisinden hesaplanan teknik göstergeler verilmiştir. Modelin başarımlı performansı kesinlik ve F-ölçütü ile değerlendirilmiş ve önerilen model Destek Vektör Makineleri yöntemiyle beraber en iyi performansı vermiştir.

### III. VERİ KÜMESİ VE KULLANILAN YÖNTEMLER

#### A. Veri Kümesi

Veri sağlayıcıdan Borsa İstanbul 100 endeksinde yer alan 3 önemli hisseye ait fiyat verileri alınmıştır. Bu hisseler Garanti Bankası (GARAN), Türk Hava Yolları A.Ş. (THYAO) ve İş Bankası (ISCTR) 'dir. Alınan fiyat verileri hisselerine ait günlük açılış, kapanış, en yüksek ve en düşük fiyatları içermektedir. Hisselerin işlem gördüğü zaman aralığı Ocak 2011-Aralık

TABLO I: KULLANILAN TEKNİK GÖSTERGELER

Gösterge	Açıklama
OP	Günlük açılış fiyatı
HI	Günlük yüksek fiyat
LO	Günlük düşük fiyat
CL	Günlük kapanış fiyatı
ROC(x)	Değişim oranı
ROCP(x)	Değişim oranı yüzdesi
%K(x)	Stokastik %K
%D(x)	%K 'nın hareketli ortalaması
BIAS(x)	x-günlük sapma
MA(x)	x-günlük hareketli ortalama
EMA(x)	x-günlük üssel hareketli ortalama
MOM(x)	Momentum
MACD(x,y)	x-günlük hareketli ortalama yakınsama ve iraksama
TEMA(x)	Üçlü üssel hareketli ortalama
PPO(x,y)	Yüzdesel fiyat osilatörü
CCI(x)	Emtia kanal indeksi
WILLR(x)	Larry Williams %R
RSI(x)	Görece güç indeksi
ULTOSC(x,y,z)	Esas osilatör
ATR(x)	Ortalama gerçek aralık
MEDPRICE(x)	x-günlük ortalama fiyat
MIDPRICE(x)	günlük ortalama fiyat
signL(x,y)	Tetikleme çizgisi
HH(x)	x-günlük en yüksek fiyat
LL(x)	x-günlük en düşük fiyat

2015 tarihlerini kapsamaktadır ve bu tarihler arasında 931 işlem günü bulunmaktadır. 931 işlem gününün ilk 663 işlem günü eğitim verisi, kalan 268 günü ise test verisi olarak ayrılmıştır.

#### B. Öznitelik Vektörlerinin Oluşturulması

Literatürde yer alan yayınlar incelendiğinde hisse senetleri fiyatlarına ait öznitelikler oluşturulurken teknik analizde kullanılan teknik göstergelerden yararlanıldığı görülmektedir [17]. Teknik göstergeler, finansal enstrümanların fiyatların analiz etmek için kullanılan matematiksel hesaplama yöntemleridir. Göstergelerin çoğu, bazı hesaplamalar sonucu fiyatların gelecekte nasıl bir yön izleyeceğini göstermeyi hedefler. Bazı göstergeler ise, trendin devam edip etmeyeceğini göstermeye çalışır. Göstergeler bulunan an ve belirlenen zaman periyodu için hesaplanır ve bu değerler yatırımcılara yol gösterir. Yatırımcılar gösterge değerlerini yorumlayıp hisse/ enstrüman fiyatlarının düşeceğine veya yükseleceğine karar vermek durumundadır. Kullanılan teknik göstergelerin seçiminde göstergelerin işaret ettiği bilgi türleri göz önünde bulundurulmalıdır. Bunun nedeni ise aynı disiplinden seçilen göstergelerin çalışacak mantıkları da aynı olacağından aynı yerlerde sinyal üretecek olmalarıdır. Çalışmada kullanılan teknik göstergelerin sınıfları ve adları Tablo I'de verilmiştir.

Kullanılacak teknik göstergeler belirlendikten sonra bu göstergelerin hangi zaman periyotları ve hangi tür fiyat verisi ile hesaplanacağına karar verilmiştir. Örneğin, SMA, EMA, ROCP ve MOM göstergeleri hisselerin kapanış fiyatları kullanılarak ve 5, 10, 15, ve 20 günlük zaman periyotları için hesaplanmıştır. WILLR, CCI, UO ve ATR göstergeleri hisselerin günlük en yüksek, en düşük ve kapanış fiyatları kullanılarak bulunmuştur. Bu göstergelerden WILLR için 4 farklı zaman periyodu kullanılarak değer bulunurken, CCI, UO ve ATR için bir zaman periyodu kullanılarak hesaplama yapılmıştır. Göstergelerin farklı zaman periyotları için hesaplanması ile birlikte her hisse için günlük 58 adet öznitelik hesaplanmıştır. Hesaplanan tüm öznitelikler en küçük-en büyük normalleştirilmesine (İng. Min-max normalization) tabi tutulmuştur.

Hesaplanan fiyat özniteliklerinin yanında, dolar ve altın fiyatlarındaki değişimin hisse senetleri üzerinde etkisini görebilmek için bu enstrümanların fiyatlarından da faydalanılmıştır. Hisselerin işlem gördüğü günlerdeki dolar ve altın fiyatları bulunarak, bu fiyatlar ile dolar ve altın için 29'ar adet teknik gösterge hesaplanmıştır. Bu özniteliklere de en küçük-en büyük normalleştirilmesi (İng. Min-max normalization) uygulanmıştır.

Çalışmada hisse fiyatlarının hangi yönde değişeceği tahmin edileceğinden, her işlem günü için değişim yönünü gösteren sınıf etiketleri oluşturulmuştur. Sınıf etiketleri aşağıdaki şekilde hesaplanmıştır:

$$r(t) = \begin{cases} 1, & \text{if } c(t) \geq c(t-1) \\ -1, & \text{diğer durumda} \end{cases} \quad (1)$$

Denklem 1'de,  $c(t)$  ve  $c(t-1)$ , sırasıyla hisselerin  $t$  ve  $t-1$ . gündeki kapanış fiyatlarını gösterirken,  $r(t)$  ise  $t$ . güne ait sınıf etiketini göstermektedir.

Her işlem günü için oluşturulan etiketler hesaplanan öznitelikler ile hizalanmış ve hisseler için veri kümeleri oluşturulmuştur. Veri kümeleri oluşturulduktan sonra Derin Sinir Ağları kullanılarak sınıflandırma aşamasına geçilmiştir.

#### C. Sınıflandırma ve Performans Değerlendirme

Çalışmada derin sinir ağlarının bir çeşidi olan Evrişimsel Sinir Ağları-ESA (İng. Convolutional Neural Network) ile hisse senetlerinin kapanış fiyatının yönü tahmin edilmiştir. ESA'nın özellikle bilgisayar görmesi ve imge sınıflandırmasındaki [18] başarılı performansından yola çıkılarak bu derin sinir ağının borsa tahmininde gösterdiği performans incelenmiştir.

Evrişimsel Sinir Ağları, temelde evrişim işleminin yapıldığı birden fazla katmandan oluşur. Yapay Sinir Ağları'nda giriş katmanındaki her bir nöronun çıkışı bir sonraki katmana giriş olarak bağlıyken, ESA'da giriş katmanının her bir yerel bölümü bir nörona bağlıdır. Ağda evrişim işlemi her katmanda farklı filtreler uygulanarak yapılır ve filtreleme işleminin sonuçları aktivasyon fonksiyonundan geçirilir. Bu işleminden sonra yapılan operasyon ise havuzlamadır (İng. Pooling). Havuzlama, filtreleme işleminden sonra yapılan alt örnekleme yöntemidir. ESA'da uygulanan havuzlama yöntemleri en büyüğü bulma ve ortalama almadır. Havuzlama işlemiyle farklı boyutlardaki giriş verilerinin ağ tarafından işlenmesi sağlanmaktadır.

ESA'nın ön plana çıkan özellikleri yer bağımsızlığı ve bütünlüktür. Örneğin, ESA kullanılarak bir imgede bir nesnenin (Örn. Ev) var olup olmadığı sınıflandırılırsa, kullanılan filtreler tüm imge üzerinde işlem yapacağından nesnenin imgenin neresinde yer aldığının önemi yoktur. Eğer imge ev nesnesini içeriyorsa havuzlama işlemiyle bu ortaya çıkarılabilmektedir. Havuzlama işlemi imgelerde dönmeye ve ölçeklemeye çözüm üretmektedir. Bu da yer bağımsızlığını getirmektedir. ESA'da giriş verisi üzerine uygulanan filtreler verinin yerel bölümlerindeki düşük düzeyli öznitelikleri her katmanda yüksek seviyeli öznitelik temsiline dönüştürürler. Bu da ESA'nın bütünlük özelliğini göstermektedir [19].

ESA'da belirlenmesi gereken hiper-parametreler bulunmaktadır. Bunlar; filtre boyutu (İng. Filter size), adım mesafesi (İng. Stride) ve havuzlama katmanındır (İng. Pooling layer). Filtre genişliği uygulanacak filtrenin giriş matrisinin her bir

TABLO II: ESA SINIFLANDIRICISI PARAMETRELERİ

Parametreler: {Arama Uzayı}
Filtre sayısı: {8, 16, 32},
Kayma miktarı: {3, 5}
Optimizasyon algoritması: {Stochastic Gradient Descent, Adadelta}
Aktivasyon fonksiyonu: {tanh, RELU}

elemanına mı yoksa matrisin bölgesine mi uygulanacağını gösterir. Filtre matrisin her bir elemanına uygulanırsa, evrişim katmanı enine doğru genişlemektedir. Adım mesafesi, uygulanacak filtrenin her aşamada kaç adım kaydırılacağını gösterir. Havuzlama katmanı ise havuzlama işleminin filtreleme işlemi sırasında her filtre bölgesine veya filtreleme sonucu oluşan öznitelik vektörüne mi uygulanacağını gösterir. ESA'da havuzlama katmanının en büyük avantajı değişken filtre ve giriş verisi boyutlarına karşın çıkış boyutunun sabit boyutlu bir vektör oluşturmastır. ESA yapı olarak birden fazla kanal uygulanmasına izin vermektedir. Kanal kullanımı giriş verisine farklı açılardan bakılmasını sağlar [20].

Yapılan çalışmada iki tür Evrişimsel Sinir Ağı kurulmuştur. 6 katmana sahip birinci ESA, sırasıyla 3 evrişim katmanına, 2 tam bağlı katmana ve 1 çıkış katmanına sahiptir. Bu ESA'ya hisselerin fiyat verilerinden ve dolar-altın fiyatlarından elde edilen veri kümeleri ayrı ayrı verilerek sınıflandırma sonuçları elde edilmiştir. İkinci ESA'da ise paralel olarak oluşturulmuş 3 evrişim katmanı, 2 tam bağlı katman ve 1 çıkış katmanı vardır. Paralel olarak oluşturulan evrişim katmanlarına ise hisselerin fiyat ve dolar-altın öznitelikleri paralel olarak verilerek iki tür veriyle sınıflandırma sonuçları alınmıştır.

Sınıflandırma işleminden sonra performans değerlendirilmesi için doğruluk oranı (İng. Accuracy) ve F-ölçütü (F-measure) metrikleri kullanılmıştır. Doğruluk oranı, sınıflandırılan örneklerden kaç tanesinin doğru sınıflandırıldığını yüzde olarak gösterirken, F-ölçütü sınıflandırma sonucunu kesinlik (İng. Precision) ve anma (İng. Recall) metriklerinin harmonik ortalamasıyla gösterir. F-ölçütüyle değerlendirme yapılırken sınıflara eşit şans verebilmek için Makro-ortalama F-ölçütü metriği kullanılmaktadır.

#### IV. DENEYLER

ESA sınıflandırıcılarının eğitiminden önce bu sınıflandırıcıların parametre kümelerinin belirlenmesi gereklidir. Bu işlem ızgara araması (İng. Grid Search) ve 5 kat çapraz doğrulaması (İng. 5-fold cross-validation) ile yapılmıştır. En iyi parametre kümesi bulunurken iterasyon sayısı 200 olarak belirlenmiştir. Eğitim sırasında doğrulama hatası oranı göz önünde bulundurularak, oranın 20 iterasyon azalmaması durumunda ağ eğitime erken durdurma uygulanmıştır. Tablo II'de gösterilen parametreler üzerinde yapılan ızgara araması sonucu her sınıflandırıcı için en iyi parametre kümesi bulunmuştur.

ESA sınıflandırıcıları için parametre kümeleri belirlendikten sonra ilk deneyler hisse senedi fiyatı ve dolar-altın fiyatlarıyla elde edilen öznitelikler ile yapılmıştır. Alınan sınıflandırma sonuçları Tablo III'de gösterilmiştir. Sonuçlar incelendiğinde fiyat öznitelikleriyle en yüksek doğruluk oranına 0.573 (0.551 Makro-ortalama F-ölçütü) ile GARAN hissesinde ulaşılırken, THYAO ve ISCTR hisseleri yaklaşık olarak aynı doğruluk oranıyla tahmin edilmiştir. Dolar-altın öznitelikleriyle alınan sonuçlarda ise en yüksek doğruluk oranına sahip hisse 0.565 (0.536 Makro-ortalama F-ölçütü) ile ISCTR olmuştur.



ISCTR hissesinde dolar-altın öznitelikleriyle fiyat özniteliklerine göre daha yüksek sınıflandırma performansı alınmıştır.

TABLO III: HİSSE YA DA DOLAR-ALTIN ÖZNİTELİKLERİ İLE SINIFLANDIRMA

	Fiyat Öznitelikleri		Dolar-Altın Öznitelikleri	
	Doğruluk Oranı	F-Ölçütü	Doğruluk Oranı	F-Ölçütü
GARAN	0.573	0.551	0.561	0.543
THYAO	0.551	0.517	0.535	0.528
ISCTR	0.554	0.481	0.565	0.536

Hem fiyat hem de dolar-altın öznitelikleriyle sınıflandırma sonuçları alındıktan sonra bu iki öznitelik birlikte kullanılarak sınıflandırma yapılmıştır. Bu iki çeşit veri kümesi ESA'nın evrişim katmanına paralel olarak verilmiş ve bu verilerden temsiller çıkarılmıştır. Çıkarılan temsiller birleştirilerek sonraki katmanlara verilmiş ve sınıflandırma süreci tamamlanmıştır. Bu yöntemle alınan sonuçlar Tablo IV'de verilmiştir. Sonuçlar incelendiğinde, GARAN, THYAO ve ISCTR hisselerinin yönü sırasıyla 0.61, 0.578 ve 0.574 doğruluk oranlarıyla tahmin edilmiş ve 3 hisse için de en yüksek doğruluk oranına iki çeşit öznitelik kullanılarak ulaşıldığı görülmüştür.

TABLO IV: HİSSE VE DOLAR-ALTIN ÖZNİTELİKLERİ İLE SINIFLANDIRMA

	Fiyat ve Dolar-Altın Öznitelikleri	
	Doğruluk Oranı	F-Ölçütü
GARAN	0.61	0.607
THYAO	0.578	0.551
ISCTR	0.574	0.545

## V. DEĞERLENDİRME

Yapılan çalışmada Borsa İstanbul 100 endeksinde işlem gören üç önemli hissenin günlük fiyat değişimleri tahmin edilmiştir. Tahmin işleminde öznitelik olarak hisse fiyatı ve dolar-altın fiyatları kullanılarak hesaplanan teknik göstergeler kullanılmıştır. Fiyat değişimini gösteren sınıf etiketleri ise hisselerin kapanış fiyatları ile bulunmuştur. Hazırlanan veri kümeleri ile iki farklı Evrişimsel Sinir Ağı eğitilmiş ve sınıflandırma performansı doğruluk oranı ve Makro-ortalama F-ölçütü metrikleriyle değerlendirilmiştir.

İlk deneyler iki farklı öznitelik çeşidi ayrı kullanılarak yapılmıştır. Fiyat öznitelikleri kullanılarak alınan sınıflandırma sonuçlarında en yüksek doğruluk oranına GARAN hissesinde ulaşılmıştır. THYAO ve ISCTR hisselerinin yönü ise yaklaşık olarak aynı doğruluk oranıyla tahmin edilmiştir. Dolar-altın öznitelikleriyle alınan sonuçlarda ise ISCTR ve GARAN hisseleri yaklaşık olarak 0.56'lık doğruluk oranıyla tahmin edilmiştir.

Sınıflandırma sürecinde fiyat öznitelikleriyle beraber dolar-altın özniteliklerinin kullanıldığı ikinci deneyde ise en yüksek doğruluk oranına 0.61 ile GARAN hissesinde ulaşılmıştır. Yapılan ilk deneylere göre her 3 hissenin tahmin performansında artış olurken en çok artış yaklaşık %4 ile GARAN hissesinde olmuştur.

## KAYNAKLAR

[1] A. Dutta, G. Bandopadhyay, and S. Sengupta, "Prediction of stock performance in indian stock market using logistic regression," *International Journal of Business and Information*, vol. 7, no. 1, 2015.

[2] L. C. Martinez, D. N. da Hora, J. R. d. M. Palotti, W. Meira, and G. L. Pappa, "From an artificial neural network to a stock market day-trading system: A case study on the bm&f bovespa," in *2009 International Joint Conference on Neural Networks*. IEEE, 2009, pp. 2006–2013.

[3] A. Kayal, "A neural networks filtering mechanism for foreign exchange trading signals," in *Intelligent Computing and Intelligent Systems (ICIS)*, 2010 IEEE International Conference on, vol. 3. IEEE, 2010, pp. 159–167.

[4] K.-j. Kim, "Financial time series forecasting using support vector machines," *Neurocomputing*, vol. 55, no. 1, pp. 307–319, 2003.

[5] H. Gunduz and Z. Cataltepe, "Borsa istanbul (bist) daily prediction using financial news and balanced feature selection," *Expert Systems with Applications*, vol. 42, no. 22, pp. 9001–9011, 2015.

[6] G. S. Atsalakis and K. P. Valavanis, "Surveying stock market forecasting techniques—part ii: Soft computing methods," *Expert Systems with Applications*, vol. 36, no. 3, pp. 5932–5941, 2009.

[7] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *Journal of machine learning research*, vol. 3, no. Mar, pp. 1157–1182, 2003.

[8] M. Bildirici and Ö. Ö. Ersin, "Improving forecasts of garch family models with the artificial neural networks: An application to the daily returns in istanbul stock exchange," *Expert Systems with Applications*, vol. 36, no. 4, pp. 7355–7362, 2009.

[9] M. A. Boyacioglu and D. Avci, "An adaptive network-based fuzzy inference system (anfis) for the prediction of stock market return: the case of the istanbul stock exchange," *Expert Systems with Applications*, vol. 37, no. 12, pp. 7908–7912, 2010.

[10] Y. Kara, M. A. Boyacioglu, and Ö. K. Baykan, "Predicting direction of stock price index movement using artificial neural networks and support vector machines: The sample of the istanbul stock exchange," *Expert systems with Applications*, vol. 38, no. 5, pp. 5311–5319, 2011.

[11] J.-L. Wu, L.-C. Yu, and P.-C. Chang, "An intelligent stock trading system using comprehensive features," *Applied Soft Computing*, vol. 23, pp. 39–50, 2014.

[12] A. K. Nassirtoussi, S. Aghabozorgi, T. Y. Wah, and D. C. L. Ngo, "Text mining of news-headlines for forex market prediction: A multi-layer dimension reduction algorithm with semantics and sentiment," *Expert Systems with Applications*, vol. 42, no. 1, pp. 306–324, 2015.

[13] Y. Peng and H. Jiang, "Leverage financial news to predict stock price movements using word embeddings and deep neural networks," *arXiv preprint arXiv:1506.07220*, 2015.

[14] L. Takeuchi and Y.-Y. A. Lee, "Applying deep learning to enhance momentum trading strategies in stocks," 2013.

[15] C. Zhu, J. Yin, and Q. Li, "A stock decision support system based on dbns," *Journal of Computational Information Systems*, vol. 10, no. 2, pp. 883–893, 2014.

[16] A. C. Türkmen and A. T. Cemgil, "An application of deep learning for trade signal prediction in financial markets," in *Signal Processing and Communications Applications Conference (SIU)*, 2015 23th. IEEE, 2015, pp. 2521–2524.

[17] I. P. Marković, M. B. Stojanović, J. Z. Stanković, and M. M. Božić, "Stock market trend prediction using support vector machines," *Facta Universitatis, Series: Automatic Control and Robotics*, vol. 13, no. 3, pp. 147–158, 2014.

[18] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *Advances in neural information processing systems*, 2012, pp. 1097–1105.

[19] J. Ngiam, Z. Chen, D. Chia, P. W. Koh, Q. V. Le, and A. Y. Ng, "Tiled convolutional neural networks," in *Advances in neural information processing systems*, 2010, pp. 1279–1287.

[20] Y. LeCun, K. Kavukcuoglu, and C. Farabet, "Convolutional networks and applications in vision," in *Circuits and Systems (ISCAS), Proceedings of 2010 IEEE International Symposium on*. IEEE, 2010, pp. 253–256.